



МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

«МИРЭА – Российский технологический университет»

РТУ МИРЭА

Институт информационных технологий (ИИТ)

Кафедра прикладной математики (ПМ)

ОТЧЕТ ПО ПРАКТИЧЕСКОЙ РАБОТЕ №1

по дисциплине «Системы управления базами данных»

Студент группы *ИНБО-20-23. Школьный И.В.*

(подпись)

Преподаватель *Трушин С.М.*

(подпись)

Москва 2025 г.

СОДЕРЖАНИЕ

РАБОТА С HADOOP	3
Запуск служб Hadoop — HDFS и YARN	3
Работа с домашними каталогами Linux и HDFS.....	4
ИЗУЧЕНИЕ И РАБОТА С КАТАЛОГАМИ HDFS	7
Исследуйте HDFS с помощью веб-интерфейса	10
В разделе Utilities(«Утилиты») выберите файловую систему	12
РАБОТА С YARN/MAPREDUCE	17
Включить YARN historyserver	18
САМОСТОЯТЕЛЬНАЯ РАБОТА	20
Работа с HDFS	20
Создание пользователей и прав	21
Исследование блоков HDFS.....	23
Работа с MapReduce	25
Мониторинг YARN	26
Исследование репликации (бонусные 2 балла).....	28


РАБОТА С HADOOP

Данная практическая работа посвящена изучению HDFS и работе с ней с помощью команд и веб-интерфейса.

Запуск служб Hadoop — HDFS и YARN

Чтобы начать использовать службу Hadoop, мы должны запустить демоны службы Hadoop. Мы делаем это как пользователь «hadoop» из нашей среды Linux.


Откроем терминал и изменим пользователя на hadoop с помощью команды `su` (Рисунок 1).



```
[student@192 ~]$ su - hadoop
Password:
Last login: Sat Sep 27 22:20:33 KST 2025
```

Рисунок 1 — Переключение на пользователя hadoop

Изменим рабочий каталог, как на Рисунке 2, и выполним необходимый сценарий, чтобы запустить службы HDFS.



```
[hadoop@192 ~]$ cd ~/hadoop/sbin
[hadoop@192 sbin]$ ./start-dfs.sh
Starting namenodes on [localhost]
localhost: namenode is running as process 2292. Stop it first and ensure /tmp/hadoop-hadoop-namenode.pid file is empty before retry.
Starting datanodes
localhost: datanode is running as process 2451. Stop it first and ensure /tmp/hadoop-hadoop-datanode.pid file is empty before retry.
Starting secondary namenodes [192.168.1.4]
192.168.1.4: secondarynamenode is running as process 2744. Stop it first and ensure /tmp/hadoop-hadoop-secondarynamenode.pid file is empty before retry.
[hadoop@192 sbin]$
```

Рисунок 2 — Переход в новый каталог и выполнение сценария

Запустим еще один скрипт, чтобы активировать службы YARN (Рисунок 3).

```
[hadoop@192 sbin]$ ./start-yarn.sh
Starting resourcemanager
resourcemanager is running as process 3079. Stop it first and ensure /tmp/hadoop-
p-hadoop-resourcemanager.pid file is empty before retry.
Starting nodemanagers
localhost: nodemanager is running as process 3214. Stop it first and ensure /tm
p/hadoop-hadoop-nodemanager.pid file is empty before retry.
[hadoop@192 sbin]$ █
```

Рисунок 3 — Запуск служб YARN

В результате выполнения серии команд были успешно запущены демон resourcemanager и nodemanagers для сервисов YARN. Выходим из сеанса как пользователь Hadoop командой exit (Рисунок 4).

```
[hadoop@192 sbin]$ exit
logout
[student@192 ~]$ █
```

Рисунок 4 — Logout

Если ОС Linux будет выключена в какой-то момент времени, придется повторить описанные выше шаги, чтобы запустить службы HDFS и YARN. Во избежание этого, не следует выключать виртуальные машины. По завершении лабораторной работы нужно выйти из виртуальной машины, используя меню «File» («Файл») > «Close» («Заккрыть») и выбрать параметр «Save the machine state» («Сохранить состояние машины»), чтобы выйти.

Работа с домашними каталогами Linux и HDFS

В терминале от имени пользователя student вводим следующую команду (Рисунок 5).

```
student : bash - Konsole
File Edit View Bookmarks Settings Help
[student@192 ~]$ hdfs dfs -ls /
Found 2 items
drwxrwxrwx - hadoop supergroup 0 2021-08-29 16:23 /tmp
drwxr-xr-x - hadoop supergroup 0 2021-08-28 23:29 /user
[student@192 ~]$ █
```

Рисунок 5 — Вывод всех каталогов

Обращаем внимание, что существует несколько каталогов. Существует каталог /tmp, где все пользователи могут читать и записывать файлы. Также есть каталог /user. Здесь находятся домашние каталоги пользователей для HDFS. При использовании HDFS у каждого пользователя может быть локальный домашний каталог Linux, а также домашний каталог HDFS. В CentOS локальный домашний каталог Linux обычно называется /home/username. Для HDFS домашний каталог находится по адресу /user/ username.

Далее изучите домашние каталоги пользователей в HDFS (Рисунок 6).

```
[student@192 ~]$ hdfs dfs -ls /user
Found 3 items
drwxr-xr-x   - hadoop  supergroup          0 2021-08-28 23:29 /user/hadoop
drwxrwxrwx   - hadoop  supergroup          0 2021-07-25 11:59 /user/hive
drwxr-xr-x   - student student          0 2021-09-10 12:20 /user/student
[student@192 ~]$ hdfs dfs -ls /user/student
Found 2 items
drwxr-xr-x   - student student          0 2021-08-28 23:21 /user/student/.hiveja
rs
-rw-r--r--   1 student student      4987 2021-08-19 22:27 /user/student/data.tx
t
[student@192 ~]$
```

Рисунок 6 — Просмотр каталогов user/ и user/student/

Исследуем домашние каталоги пользователей для Linux (Рисунок 7).

```
[student@192 ~]$ cd /home
[student@192 home]$ ls -l
total 8
drwxr-xr-x. 20 hadoop  hadoop  4096 Sep 27 04:53 hadoop
drwx-----.  4 hue    hue    96 Aug 19 2021 hue
drwxr-xr-x.  7 kafka  kafka  155 Jul 25 2021 kafka
drwx-----. 26 student student 4096 Sep 27 04:38 student
[student@192 home]$ cd /home/student
[student@192 ~]$ ls -l
total 4
drwxrwxr-x.  6 student student 4096 Sep 26 2021 Data
drwxr-xr-x.  2 student student   6 Jul 25 2021 Desktop
drwxr-xr-x.  2 student student   6 Aug  4 2021 Documents
drwxr-xr-x.  2 student student   6 Jul 25 2021 Downloads
drwxrwxr-x.  6 student student  54 Sep 26 2021 Labs
drwxr-xr-x.  2 student student   6 Jul 25 2021 Music
drwxr-xr-x.  2 student student   6 Jul 25 2021 Pictures
drwxr-xr-x.  2 student student   6 Jul 25 2021 Public
drwxrwxr-x.  2 student student 279 Sep 26 2021 Scripts
drwxr-xr-x.  2 student student   6 Jul 25 2021 Templates
drwxr-xr-x.  2 student student   6 Jul 25 2021 Videos
[student@192 ~]$ cd /home/
[student@192 home]$
```

Рисунок 7 — Исследование домашних каталогов

Добавим нового пользователя, зададим ему пароль и добавим его в группу wheel. Команды изображены на Рисунке 8.

```
[student@192 ~]$ sudo useradd student2 -m
[student@192 ~]$ sudo passwd student2
bash: sudo: command not found
[student@192 ~]$ sudo passwd student2
Changing password for user student2.
New password:
BAD PASSWORD: The password contains the user name in some form
Retype new password:
passwd: all authentication tokens updated successfully.
[student@192 ~]$ sudo usermod -aG wheel student2
[student@192 ~]$
```

Рисунок 8 — Создание пользователя student2

Войдем в созданного пользователя, перейдем в домашний каталог, получим список каталога, выведем текущую директорию и группы, которым принадлежит student2 (Рисунок 9).

```
[student@192 ~]$ su - student2
Password:
[student2@192 ~]$ cd
[student2@192 ~]$ ls -l
total 0
[student2@192 ~]$ pwd
/home/student2
[student2@192 ~]$ groups
student2 wheel
[student2@192 ~]$
```




Рисунок 9 — Тестирование новой учетной записи


Далее необходимо добавить домашний каталог HDFS для пользователя student2. Список команд и проверка корректного создания каталога продемонстрированы на Рисунке 10.

```
[hadoop@192 ~]$ hdfs dfs -mkdir /user/student2
[hadoop@192 ~]$ hdfs dfs -ls /user/student2
[hadoop@192 ~]$ hdfs dfs -ls /user/
Found 4 items
drwxr-xr-x - hadoop supergroup 0 2021-08-28 23:29 /user/hadoop
drwxrwxrwx - hadoop supergroup 0 2021-07-25 11:59 /user/hive
drwxr-xr-x - student student 0 2021-09-10 12:20 /user/student
drwxr-xr-x - hadoop supergroup 0 2025-09-27 05:33 /user/student2
[hadoop@192 ~]$
```

Рисунок 10 — Создание домашнего каталога HDFS для student2

ИЗУЧЕНИЕ И РАБОТА С КАТАЛОГАМИ HDFS

Создадим подкаталог в домашнем каталоге студента HDFS и назовем его «MRtest» (Рисунок 11).



```
[student2@192 ~]$ su - student
Password:
Last login: Sat Sep 27 04:38:13 KST 2025 on :0
[student@192 ~]$ hdfs dfs -mkdir MRtest
[student@192 ~]$ hdfs dfs -ls /user/student
Found 3 items
drwxr-xr-x  - student student      0 2021-08-28 23:21 /user/student/.hiveJars
drwxr-xr-x  - student student      0 2025-09-27 05:51 /user/student/MRtest
-rw-r--r--  1 student student 4987 2021-08-19 22:27 /user/student/data.txt
[student@192 ~]$
```

Рисунок 11 — Создание каталога MRtest

Перейдем в каталог ~/Data и посмотрим его содержимое (Рисунок 12).

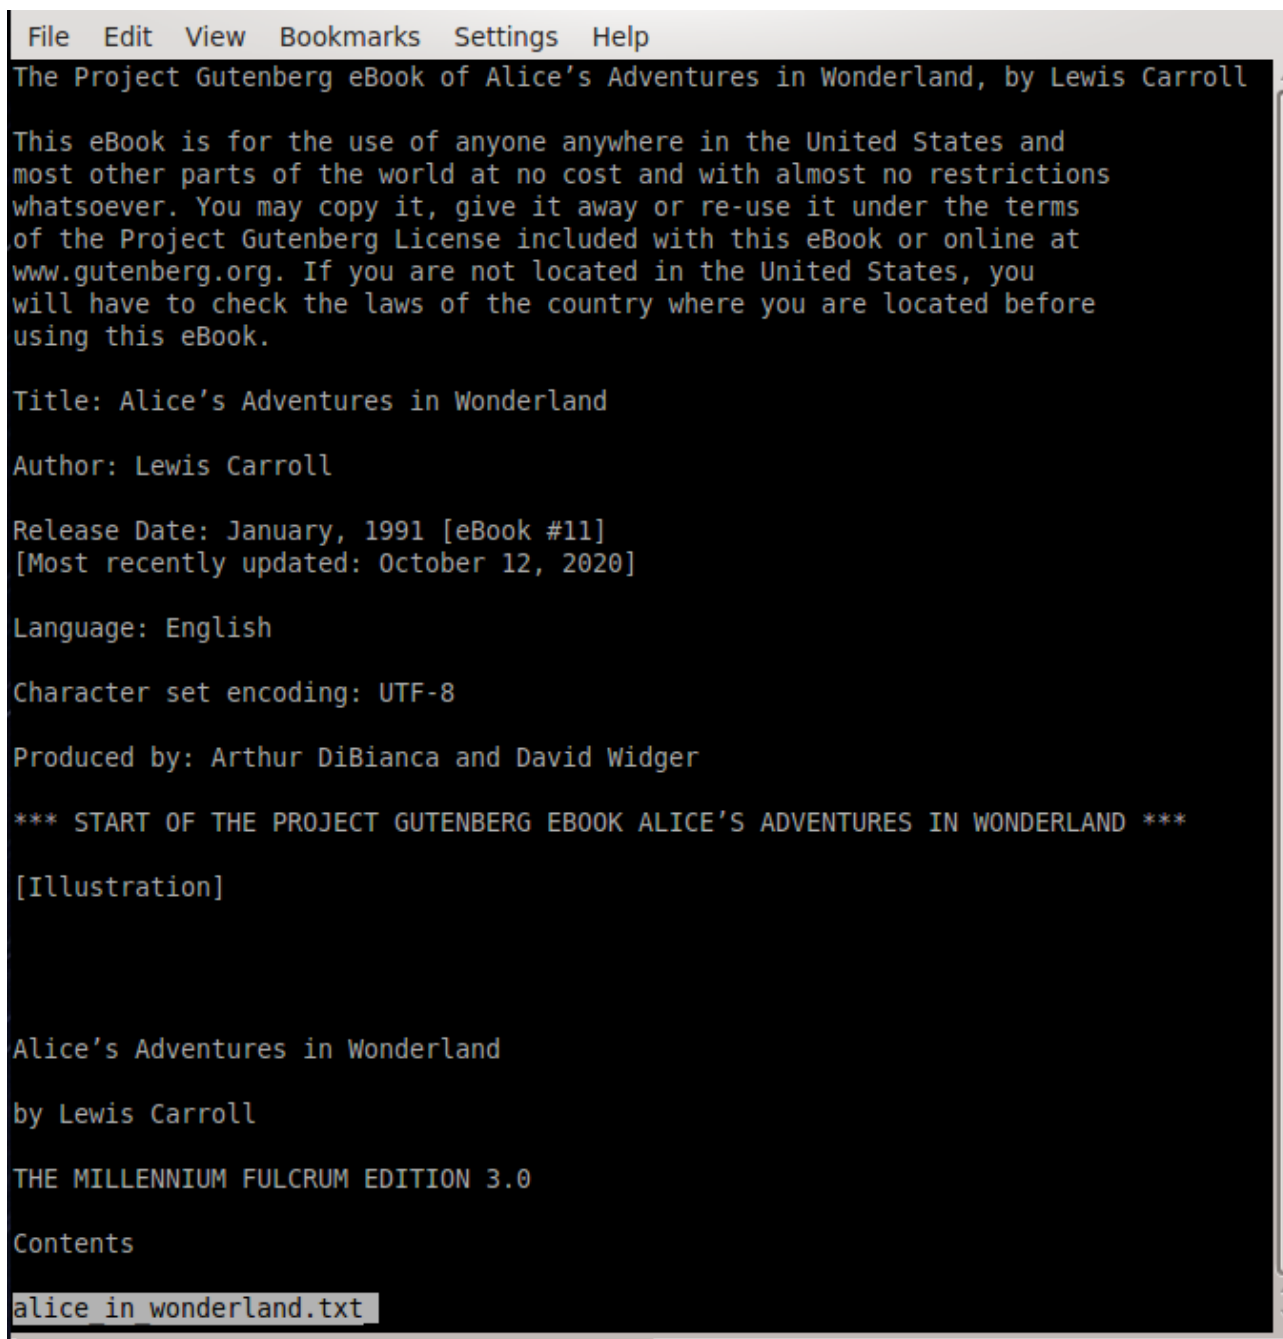

```

[student@192 ~]$ cd ~/Data
[student@192 Data]$ ls -l
total 2396
-rwxr-x---. 1 student student 170549 Sep 16 2021 alice_in_wonderland.txt
-rwxr-x---. 1 student student 1423098 Aug 10 2021 anonymous-msweb.data
-rwxr-x---. 1 student student 545933 Sep 20 2021 author_phone.json
-rw-rw-r--. 1 student student 7632 Sep 11 2021 clients.json
-rwxr-x---. 1 student student 6664 Sep 17 2021 cust_phone.json
lrwxrwxrwx. 1 student student 76 Sep 17 2021 dir1 -> /usr/local/spark3/spark
-3.1.2-bin-hadoop3.2/examples/src/main/resources/dir1
lrwxrwxrwx. 1 student student 86 Sep 17 2021 employees.json -> /usr/local/sp
ark3/spark-3.1.2-bin-hadoop3.2/examples/src/main/resources/employees.json
lrwxrwxrwx. 1 student student 86 Sep 17 2021 full_user.avsc -> /usr/local/sp
ark3/spark-3.1.2-bin-hadoop3.2/examples/src/main/resources/full_user.avsc
drwxrwxr-x. 2 student student 118 Sep 16 2021 json_files
lrwxrwxrwx. 1 student student 79 Sep 17 2021 kv1.txt -> /usr/local/spark3/sp
ark-3.1.2-bin-hadoop3.2/examples/src/main/resources/kv1.txt
lrwxrwxrwx. 1 student student 82 Sep 17 2021 people.csv -> /usr/local/spark3
/spark-3.1.2-bin-hadoop3.2/examples/src/main/resources/people.csv
lrwxrwxrwx. 1 student student 83 Sep 17 2021 people.json -> /usr/local/spark
3/spark-3.1.2-bin-hadoop3.2/examples/src/main/resources/people.json
lrwxrwxrwx. 1 student student 82 Sep 17 2021 people.txt -> /usr/local/spark3
/spark-3.1.2-bin-hadoop3.2/examples/src/main/resources/people.txt
-rwxr-x---. 1 student student 4987 Aug 9 2021 pig_data1.txt
-rwxr-x---. 1 student student 5240 Aug 9 2021 pig_data2.txt
drwxr-x---. 2 student student 249 Sep 19 2021 post_records
-rwxr-x---. 1 student student 94005 Sep 10 2021 sales.csv
drwxrwxr-x. 2 student student 79 Aug 5 2021 scripts
-rwxr-x---. 1 student student 173134 Sep 17 2021 spark-avro_2.12-3.1.2.jar
lrwxrwxrwx. 1 student student 81 Sep 17 2021 user.avsc -> /usr/local/spark3/
spark-3.1.2-bin-hadoop3.2/examples/src/main/resources/user.avsc
lrwxrwxrwx. 1 student student 82 Sep 17 2021 users.avro -> /usr/local/spark3
/spark-3.1.2-bin-hadoop3.2/examples/src/main/resources/users.avro
lrwxrwxrwx. 1 student student 81 Sep 17 2021 users.orc -> /usr/local/spark3/
spark-3.1.2-bin-hadoop3.2/examples/src/main/resources/users.orc
lrwxrwxrwx. 1 student student 85 Sep 17 2021 users.parquet -> /usr/local/spa
rk3/spark-3.1.2-bin-hadoop3.2/examples/src/main/resources/users.parquet
drwxrwxr-x. 2 student student 4096 Sep 23 2021 weblogs
[student@192 Data]$ █

```

Рисунок 12 — Содержимое каталога ~/Data

Просмотрим файл `alice_in_wonderland.txt` с помощью команды `less` (Рисунок 13).

A screenshot of a text editor window with a menu bar (File, Edit, View, Bookmarks, Settings, Help) and a dark background. The text is displayed in a light green monospaced font. The content is the Project Gutenberg eBook of 'Alice's Adventures in Wonderland' by Lewis Carroll, including the license text, title, author, release date, language, character set encoding, producers, and a table of contents. The file name 'alice_in_wonderland.txt' is highlighted in the bottom left corner.

```
File Edit View Bookmarks Settings Help
The Project Gutenberg eBook of Alice's Adventures in Wonderland, by Lewis Carroll

This eBook is for the use of anyone anywhere in the United States and
most other parts of the world at no cost and with almost no restrictions
whatsoever. You may copy it, give it away or re-use it under the terms
of the Project Gutenberg License included with this eBook or online at
www.gutenberg.org. If you are not located in the United States, you
will have to check the laws of the country where you are located before
using this eBook.

Title: Alice's Adventures in Wonderland

Author: Lewis Carroll

Release Date: January, 1991 [eBook #11]
[Most recently updated: October 12, 2020]

Language: English

Character set encoding: UTF-8

Produced by: Arthur DiBianca and David Widger

*** START OF THE PROJECT GUTENBERG EBOOK ALICE'S ADVENTURES IN WONDERLAND ***

[Illustration]

Alice's Adventures in Wonderland
by Lewis Carroll


THE MILLENNIUM FULCRUM EDITION 3.0

Contents

alice_in_wonderland.txt
```

Рисунок 13 — Содержимое файла `alice_in_wonderland.txt`

Переместим этот файл из текущего каталога в ранее созданный MRtest (Рисунок 14).

A screenshot of a terminal window with a dark background and light green text. The terminal shows a user at a prompt moving a file from the current directory to a directory named 'MRtest' using the 'hdfs dfs -put' command. The subsequent 'hdfs dfs -ls' command shows the file has been successfully moved to the new location.

```
[student@192 Data]$ hdfs dfs -put ~/Data/alice_in_wonderland.txt /user/student/MRt
est
[student@192 Data]$ hdfs dfs -ls /user/student/MRtest
Found 1 items
-rw-r--r--  1 student student    170549 2025-09-27 06:01 /user/student/MRtest/al
ice_in_wonderland.txt
[student@192 Data]$
```

Рисунок 14 — Перемещение файла

Исследуйте HDFS с помощью веб-интерфейса

Откроем браузер Firefox и в нем веб-интерфейс Namenode (Рисунок 15).




Рисунок 15 — Веб-интерфейс Namenode

Изучим вкладку «Overview» («Обзор»).

На этой вкладке мы можем увидеть обзорную информацию для настроенной HDFS. Мы также можем получить сводную информацию о статистике использования диска и состоянии узлов данных.

Изучим вкладку «Overview» («Обзор»).

На этой вкладке мы можем увидеть обзорную информацию для настроенной HDFS. Мы также можем получить сводную информацию о статистике использования диска и состоянии узлов данных.

Изучим вкладку «Datanodes» («Узлы данных») и «Datanode Volume Failures» («Сбои тома данных»).

На этих вкладках мы можем просматривать состояние и статистику узлов данных. Поскольку наша лабораторная среда на самом деле не является кластером, мы увидим только 1 узел данных.

Изучим вкладку «Snapshot» («Снимок»).

В HDFS можно делать снимки каталогов. Если есть какие-либо сохраненные снимки, мы можем просмотреть информацию о них на этой вкладке.

Изучим вкладку «Startup Progress» («Ход запуска»).

Мы можем просмотреть информацию о запуске для служб HDFS, включая загрузку файла fsimage и edits.

Просмотрим все существующие файлы fsimage и edits через терминал (Рисунок 16). Для этого необходимо воспользоваться утилитой ls. Пусть до файлов /home/Hadoop/hadoopdata/hdfs/namenode/current/.




Рисунок 17 — Выбор файловой системы

Перейдем в тот каталог, куда переместили ранее текстовый файл (Рисунок 18).




Рисунок 18 — Просмотр каталога с текстовым файлом

Нажмем на файл, чтобы открыть всплывающее окно с информацией о блоке (Рисунок 19).




Рисунок 19 — Информация о файле

В нашей псевдо-распределенной среде Hadoop мы установили коэффициент репликации равным 1, так как он есть только на машине в кластере. Когда вы нажмете на информацию о блоке, вы увидите только один блок.

В реальном кластере коэффициент репликации обычно равен 3, и мы можем видеть информацию обо всех трех блоках, включая расположение этих блоков.

Примем во внимание (скопируем) значение Block ID (идентификатор блока) и Block Pool ID (идентификатор пула блоков). Мы перейдем к каталогу, где HDFS фактически хранит эти блоки.

Откроем терминал и войдем в систему как пользователь `hadoop`. Воспользуемся командой Linux `find` для поиска Block Pool ID (идентификатор пула блоков). Демонстрацию работы смотреть на Рисунке 20.


```
[student@192 ~]$ su - hadoop
Password:
Last login: Sat Sep 27 22:24:20 KST 2025 on pts/1
[hadoop@192 ~]$ sudo find / -name BP-1852854795-127.0.0.1-1627178914058 -print
[sudo] password for hadoop:
/home/hadoop/hadoopdata/hdfs/datanode/current/BP-1852854795-127.0.0.1-1627178914058
[hadoop@192 ~]$
```

Рисунок 20 — поиск Block Pool ID

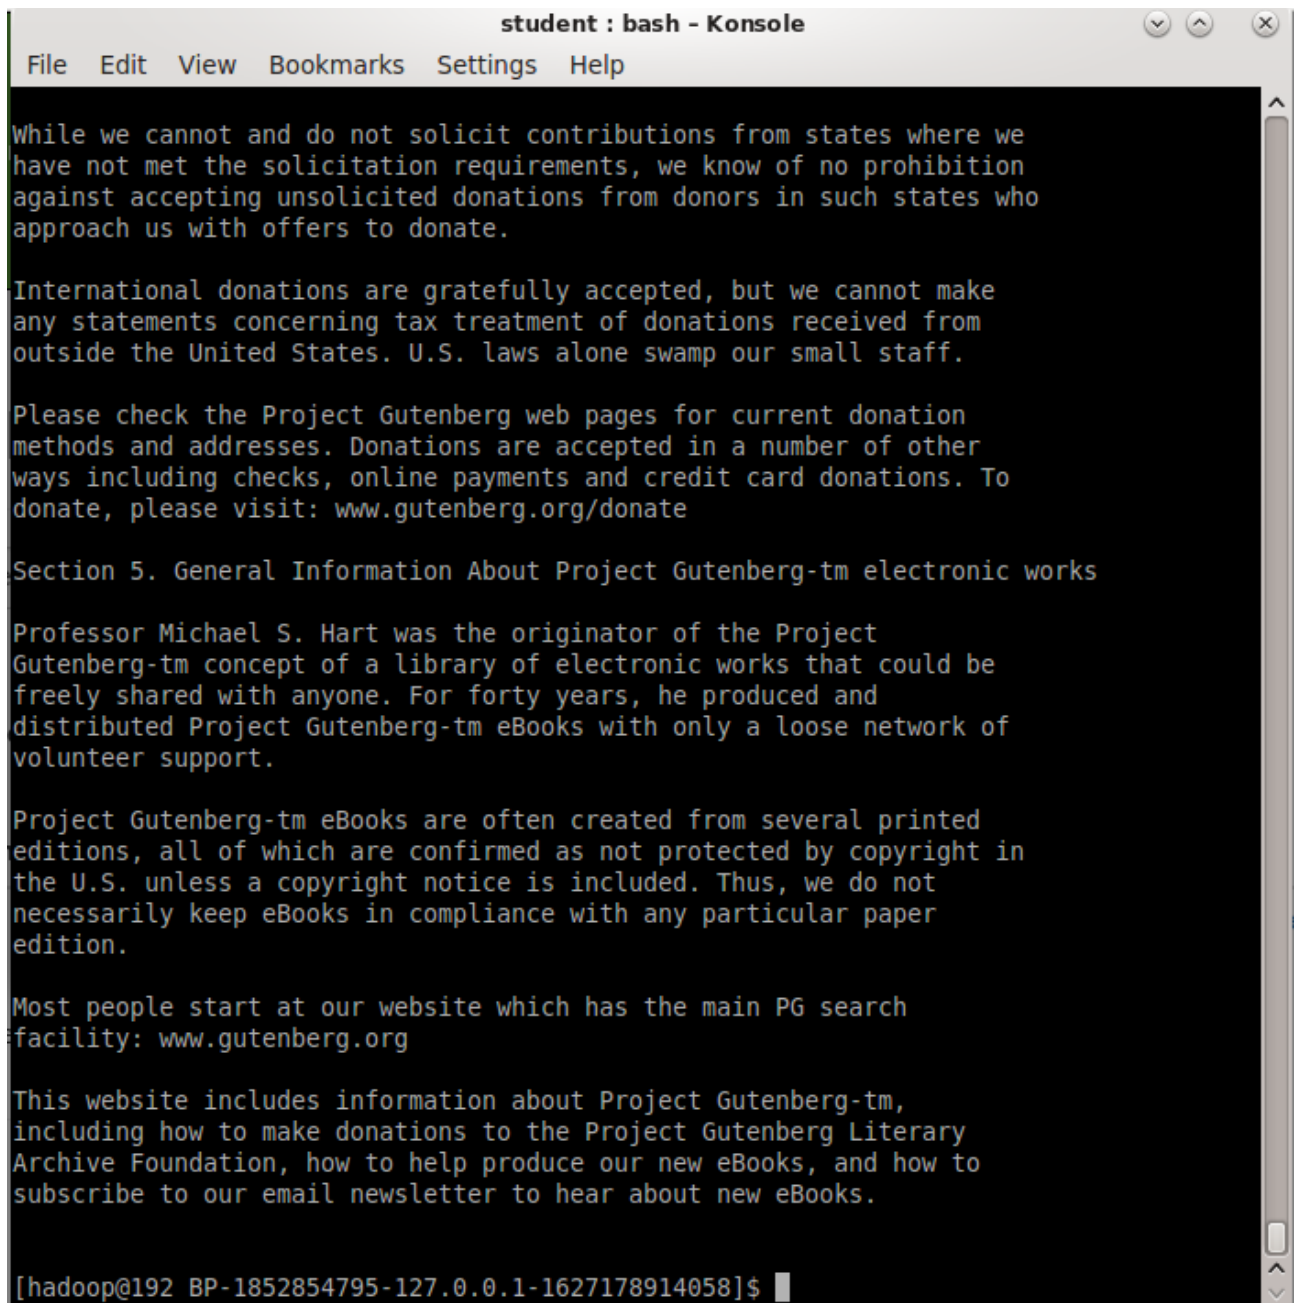
Перейдем в каталог, где был найден Block Pool ID (идентификатор пула блоков), и изучим его (Рисунок 21).

```
[hadoop@192 ~]$ cd /home/hadoop/hadoopdata/hdfs/datanode/current/BP-1852854795-127.0.0.1-1627178914058
[hadoop@192 BP-1852854795-127.0.0.1-1627178914058]$ sudo find . -name *1073742098* -print
[sudo] password for hadoop:
./current/finalized/subdir0/subdir1/blk_1073742098_1274.meta
./current/finalized/subdir0/subdir1/blk_1073742098
[hadoop@192 BP-1852854795-127.0.0.1-1627178914058]$
```

Рисунок 21 — Просмотр содержимого найденного каталога

Мы снова воспользуемся командой `find` для поиска блоков данных. На этот раз мы скажем `find` начать поиск с текущего каталога с точечной нотацией (`.`). Получилось увидеть два найденных файла. Один из файлов будет содержать метаданные. Это бинарный файл, и мы не сможем увидеть его содержимое. Однако другой файл является текстовым, а фактическое содержимое, которое Hadoop сохранило для файла `alice_in_wonderland.txt`, сохраняется в HDFS.

Воспользуемся командой `cat`, чтобы просмотреть содержимое текстового файла (Рисунок 22).



```
student : bash - Konsole
File Edit View Bookmarks Settings Help

While we cannot and do not solicit contributions from states where we
have not met the solicitation requirements, we know of no prohibition
against accepting unsolicited donations from donors in such states who
approach us with offers to donate.

International donations are gratefully accepted, but we cannot make
any statements concerning tax treatment of donations received from
outside the United States. U.S. laws alone swamp our small staff.

Please check the Project Gutenberg web pages for current donation
methods and addresses. Donations are accepted in a number of other
ways including checks, online payments and credit card donations. To
donate, please visit: www.gutenberg.org/donate

Section 5. General Information About Project Gutenberg-tm electronic works

Professor Michael S. Hart was the originator of the Project
Gutenberg-tm concept of a library of electronic works that could be
freely shared with anyone. For forty years, he produced and
distributed Project Gutenberg-tm eBooks with only a loose network of
volunteer support.

Project Gutenberg-tm eBooks are often created from several printed
editions, all of which are confirmed as not protected by copyright in
the U.S. unless a copyright notice is included. Thus, we do not
necessarily keep eBooks in compliance with any particular paper
edition.

Most people start at our website which has the main PG search
facility: www.gutenberg.org

This website includes information about Project Gutenberg-tm,
including how to make donations to the Project Gutenberg Literary
Archive Foundation, how to help produce our new eBooks, and how to
subscribe to our email newsletter to hear about new eBooks.

[hadoop@192 BP-1852854795-127.0.0.1-1627178914058]$
```


Рисунок 22 — Просмотр содержимого файла

РАБОТА С YARN/MAPREDUCE

Мы будем использовать файл `alice_in_wonderland.txt`, который был сохранен в HDFS, для запуска программы MapReduce подсчета слов.

Включить YARN historyserver

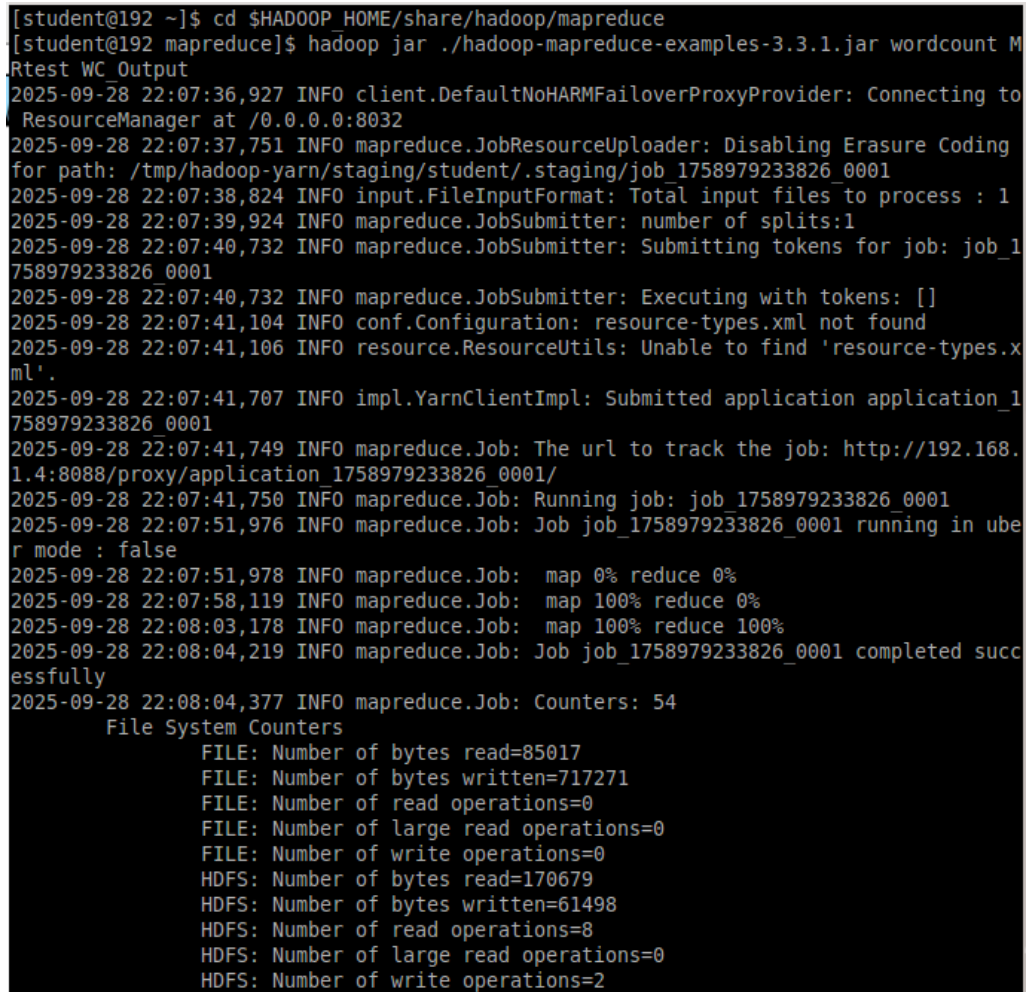
Откроем новый терминал как hadoop и запустим historyserver (Рисунок 23).



```
File Edit View Bookmarks Settings Help
[student@192 ~]$ su - hadoop
Password:
Last login: Sun Sep 28 21:49:39 KST 2025 on pts/1
[hadoop@192 ~]$ cd $HADOOP_HOME/sbin
[hadoop@192 sbin]$ mr-jobhistory-daemon.sh start historyserver
WARNING: Use of this script to start the MR JobHistory daemon is deprecated.
WARNING: Attempting to execute replacement "mapred --daemon start" instead.
historyserver is running as process 3518. Stop it first and ensure /tmp/hadoop-hadoo
p-historyserver.pid file is empty before retry.
[hadoop@192 sbin]$
```

Рисунок 23 — Запуск historyserver

Запускаем скрипт подсчета слов (Рисунок 24).



```
[student@192 ~]$ cd $HADOOP_HOME/share/hadoop/mapreduce
[student@192 mapreduce]$ hadoop jar ./hadoop-mapreduce-examples-3.3.1.jar wordcount M
Rtest WC Output
2025-09-28 22:07:36,927 INFO client.DefaultNoHARMAFailoverProxyProvider: Connecting to
ResourceManager at /0.0.0.0:8032
2025-09-28 22:07:37,751 INFO mapreduce.JobResourceUploader: Disabling Erasure Coding
for path: /tmp/hadoop-yarn/staging/student/.staging/job_1758979233826_0001
2025-09-28 22:07:38,824 INFO input.FileInputFormat: Total input files to process : 1
2025-09-28 22:07:39,924 INFO mapreduce.JobSubmitter: number of splits:1
2025-09-28 22:07:40,732 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1
758979233826_0001
2025-09-28 22:07:40,732 INFO mapreduce.JobSubmitter: Executing with tokens: []
2025-09-28 22:07:41,104 INFO conf.Configuration: resource-types.xml not found
2025-09-28 22:07:41,106 INFO resource.ResourceUtils: Unable to find 'resource-types.x
ml'.
2025-09-28 22:07:41,707 INFO impl.YarnClientImpl: Submitted application application_1
758979233826_0001
2025-09-28 22:07:41,749 INFO mapreduce.Job: The url to track the job: http://192.168.
1.4:8088/proxy/application_1758979233826_0001/
2025-09-28 22:07:41,750 INFO mapreduce.Job: Running job: job_1758979233826_0001
2025-09-28 22:07:51,976 INFO mapreduce.Job: Job job_1758979233826_0001 running in ube
r mode : false
2025-09-28 22:07:51,978 INFO mapreduce.Job: map 0% reduce 0%
2025-09-28 22:07:58,119 INFO mapreduce.Job: map 100% reduce 0%
2025-09-28 22:08:03,178 INFO mapreduce.Job: map 100% reduce 100%
2025-09-28 22:08:04,219 INFO mapreduce.Job: Job job_1758979233826_0001 completed succ
essfully
2025-09-28 22:08:04,377 INFO mapreduce.Job: Counters: 54
File System Counters
FILE: Number of bytes read=85017
FILE: Number of bytes written=717271
FILE: Number of read operations=0
FILE: Number of large read operations=0
FILE: Number of write operations=0
HDFS: Number of bytes read=170679
HDFS: Number of bytes written=61498
HDFS: Number of read operations=8
HDFS: Number of large read operations=0
HDFS: Number of write operations=2
```

Рисунок 24 — Запуск скрипта

Во время работы программы откроем Firefox и перейдем к веб-интерфейсу YARN по адресу <http://localhost:8088>. Нажмем «Приложения» в меню левой

вкладки. Мы должны увидеть, что наше приложение работает. Application id (идентификатор приложения) был присвоен заданию. Нажмем на ссылку для идентификатора приложения (Рисунки 25-26).




Рисунок 25 — localhost




Рисунок 26 — Идентификатор приложения

Перейдем в узел, что указан в таблице (Рисунок 27).



► ResourceManager	NodeManager information
▼ NodeManager	
Node Information	
List of Applications	
List of Containers	
► Tools	
Total Vmem allocated for Containers	16.80 GB
Vmem enforcement enabled	true
Total Pmem allocated for Container	8 GB
Pmem enforcement enabled	true
Total VCores allocated for Containers	8
Resource types	memory-mb (unit=Mb), vcores
NodeHealthyStatus	true
LastNodeHealthTime	Sun Sep 28 23:14:33 KST 2025
NodeHealthReport	
NodeManager started on	Sat Sep 27 22:20:29 KST 2025
NodeManager Version:	3.3.1 from a3b9c37a397ad4188041dd80621bdeefc46885f2 by ubuntu source checksum bac7931c6577eaa849b289247f5b4ab3 on 2021-06-15T05:22Z
Hadoop Version:	3.3.1 from a3b9c37a397ad4188041dd80621bdeefc46885f2 by ubuntu source checksum 88a4ddb2299aca054416d6b7f81ca55 on 2021-06-15T05:13Z

Рисунок 27 — Информация об узле

Мы можем перезапустить задание. Если это нужно сделать, придется удалить выходной каталог. Параметр `-r` команды `rm` (удалить) указывает Hadoop также рекурсивно удалить все подпапки (Рисунок 28).

```
[student@192 mapreduce]$ hdfs dfs -rm -r WC_Output
Deleted WC_Output
[student@192 mapreduce]$
```

Рисунок 28 — Удаление выходного каталога

САМОСТОЯТЕЛЬНАЯ РАБОТА

Работа с HDFS

1. Создайте в своем домашнем каталоге HDFS подкаталог `test_data`.
2. Скопируйте туда любой другой текстовый файл из директории `/home/student/data` (например, `sample.txt`).

3. Проверьте размер файла в HDFS и сравните его с размером в локальной файловой системе. Объясните разницу.

Сперва создаем новый подкаталог и называем его `test_data`. Затем переходим в каталог `~/Data` и просматриваем файлы, из которых один выберем для копирования в созданный подкаталог (Рисунок 29).

```
[student@192 ~]$ hdfs dfs -mkdir test_data
[student@192 ~]$ cd ~/Data
[student@192 Data]$ ls
alice_in_wonderland.txt  employees.json  people.txt      spark-avro_2.12-3.1.2.jar
anonymous-msweb.data    full_user.avsc  pig_data1.txt   user.avsc
author_phone.json       json_files      pig_data2.txt   users.avro
clients.json            kv1.txt         post_records    users.orc
cust_phone.json         people.csv      sales.csv       users.parquet
dir1                    people.json     scripts         weblogs
```

Рисунок 29 — Создание подкаталога

Допустим, скопируем файл `people.txt`. Введем необходимую команду, используя утилиту `-put`, и посмотрим результат. Порядок скриптов изображен на Рисунке 30.

```
[student@192 Data]$ cat people.txt
Michael, 29
Andy, 30
Justin, 19
[student@192 Data]$ hdfs dfs -put ~Data/people.txt /user/student/test_data
put: '~Data/people.txt': No such file or directory
[student@192 Data]$ hdfs dfs -put ~/Data/people.txt /user/student/test_data
[student@192 Data]$ ls /user/student/test_data
ls: cannot access /user/student/test_data: No such file or directory
[student@192 Data]$ hdfs dfs -ls /user/student/test_data
Found 1 items
-rw-r--r--  1 student student          32 2025-09-28 23:36 /user/student/test_data/people.txt
[student@192 Data]$
```

Рисунок 30 — Выполненное задание

Создание пользователей и прав

1. Создайте нового пользователя Linux с именем `analyst1`.
2. Создайте для него домашний каталог в HDFS `/user/analyst1`.
3. Настройте права так, чтобы только `analyst1` и `student` имели доступ к этому каталогу.

4. Проверьте корректность прав, попробовав обратиться к каталогу из учетной записи другого пользователя.

Создадим нового пользователя `analyst1`, сделаем ему пароль (Рисунок 31).

```
[student@192 ~]$ sudo useradd analyst1 -m
[student@192 ~]$ sudo passwd analyst1
Changing password for user analyst1.
New password:
BAD PASSWORD: The password contains the user name in some form
Retype new password:
passwd: all authentication tokens updated successfully.
[student@192 ~]$ su - hadoop
Password:
Last login: Sun Sep 28 22:04:14 KST 2025 on pts/2
[hadoop@192 ~]$ hdfs dfs -mkdir /user/analyst1
[hadoop@192 ~]$ hdfs dfs -ls /user
Found 5 items
drwxr-xr-x - hadoop supergroup 0 2025-09-28 23:51 /user/analyst1
drwxr-xr-x - hadoop supergroup 0 2021-08-28 23:29 /user/hadoop
drwxrwxrwx - hadoop supergroup 0 2021-07-25 11:59 /user/hive
drwxr-xr-x - student student 0 2025-09-28 23:30 /user/student
drwxr-xr-x - hadoop supergroup 0 2025-09-27 05:33 /user/student2
```

Рисунок 31 — Создание пользователя `analyst1`

Затем создадим группу `analysts`, в которую поместим пользователей `student` и `analyst1` (Рисунок 32).

```
[student@192 ~]$ sudo groupadd analysts
[student@192 ~]$ groups
student wheel supergroup
[student@192 ~]$ sudo usermod -aG analysts analyst1
[student@192 ~]$ groups
student wheel supergroup
[student@192 ~]$ sudo usermod -aG analysts student
[student@192 ~]$ groups
student wheel supergroup
[student@192 ~]$ getent group analysts
analysts:x:1007:analyst1,student
```

Рисунок 32 — Формирование группы `analysts`

Установим права каталога только у этой группы, зайдём с другого пользователя и попробуем проверить содержимое (Рисунок 33).

```

-[student@192 ~]$ hdfs dfs -setfacl -b /user/analyst1
ar[student@192 ~]$ hdfs dfs -chmod 750 /user/analyst1
-[student@192 ~]$ hdfs dfs -ls -d /user/analyst1
drwxr-x---  - analyst1 analysts          0 2025-09-29 00:12 /user/analyst1
-[student@192 ~]$ hdfs dfs -getfacl /user/analyst1
-# file: /user/analyst1
-# owner: analyst1
-# group: analysts
e1user::rwx
ucgroup::r-x
p0other::---

[student@192 ~]$ su - student2
Password:
Last login: Mon Sep 29 00:19:45 KST 2025 on pts/2
-[student2@192 ~]$ hdfs dfs -ls /user/analyst1
-ls: Permission denied: user=student2, access=READ_EXECUTE, inode="/user/analyst1":ana
e1lyst1:analysts:drwxr-x---
uc[student2@192 ~]$ 

```

Рисунок 33 — Присвоение прав к каталогу и проверка

Как и ожидалось, в доступе отказано, значит, задание выполнено.

Исследование блоков HDFS

1. Найдите Block ID и Block Pool ID для файла `alice_in_wonderland.txt`.
2. Определите количество блоков, на которые файл был разделён в HDFS.
3. Сделайте вывод: от чего зависит количество блоков для одного файла?

Выполняем поиск Block ID и Block Pool ID для файла `alice_in_wonderland.txt` (Рисунок 34).


```

[student@192 ~]$ hdfs fsck /user/student/MRtest/alice_in_wonderland.txt -files -block
s -locations
Connecting to namenode via http://localhost:50070/fsck?ugi=student&files=1&blocks=1&l
ocations=1&path=%2Fuser%2Fstudent%2FMRtest%2Falice_in_wonderland.txt
FSCK started by student (auth:SIMPLE) from /127.0.0.1 for path /user/student/MRtest/a
lice_in_wonderland.txt at Mon Sep 29 00:51:29 KST 2025

/user/student/MRtest/alice_in_wonderland.txt 170549 bytes, replicated: replication=1,
1 block(s): OK
0. BP-1852854795-127.0.0.1-1627178914058:blk_1073742098_1274 len=170549 Live repl=1
[DatanodeInfoWithStorage[127.0.0.1:9866,DS-2ec60128-7415-434e-9f40-22713e2c6695,DISK]
]

Status: HEALTHY
Number of data-nodes: 1
Number of racks: 1
Total dirs: 0
Total symlinks: 0

Replicated Blocks:
Total size: 170549 B
Total files: 1
Total blocks (validated): 1 (avg. block size 170549 B)
Minimally replicated blocks: 1 (100.0 %)
Over-replicated blocks: 0 (0.0 %)
Under-replicated blocks: 0 (0.0 %)
Mis-replicated blocks: 0 (0.0 %)
Default replication factor: 1
Average block replication: 1.0
Missing blocks: 0
Corrupt blocks: 0
Missing replicas: 0 (0.0 %)
Blocks queued for replication: 0

Erasure Coded Block Groups:
Total size: 0 B
Total files: 0
Total block groups (validated): 0
Minimally erasure-coded block groups: 0
Over-erasure-coded block groups: 0
Under-erasure-coded block groups: 0
Unsatisfactory placement block groups: 0
Average block group size: 0.0
Missing block groups: 0
Corrupt block groups: 0
Missing internal blocks: 0
Blocks queued for replication: 0
FSCK ended at Mon Sep 29 00:51:29 KST 2025 in 2 milliseconds

```

Рисунок 34 — Поиск данных для текстового файла

Замечаем все необходимые сведения. Размер файла равен около 170 Кб, что не превышает размер блока HDFS по умолчанию (128 или 64 Мб). Именно поэтому файл поместился в один блок.

Работа с MapReduce


1. Запустите задание wordcount не только на файле alice_in_wonderland.txt, но и на любом другом текстовом файле из папки /home/student/data.
2. Сравните количество уникальных слов в разных файлах.
3. Сформулируйте, чем может быть полезна программа wordcount в реальных проектах анализа данных.

Прделаем ту же работу, что уже делали ранее, только теперь для файла people.txt, что лежит в каталоге test_data (Рисунок 35).

```
[student@192 mapreduce]$ hadoop jar ./hadoop-mapreduce-examples-3.3.1.jar wordcount test_data WC_Outpu
t
2025-09-29 01:08:44,823 INFO client.DefaultNoHARMFailoverProxyProvider: Connecting to ResourceManager
at /0.0.0.0:8032
2025-09-29 01:08:45,265 INFO mapreduce.JobResourceUploader: Disabling Erasure Coding for path: /tmp/ha
dooop-yarn/staging/student/.staging/job_1758979233826_0002
2025-09-29 01:08:45,484 INFO input.FileInputFormat: Total input files to process : 1
2025-09-29 01:08:46,401 INFO mapreduce.JobSubmitter: number of splits:1
2025-09-29 01:08:46,953 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1758979233826_0002
2025-09-29 01:08:46,954 INFO mapreduce.JobSubmitter: Executing with tokens: []
2025-09-29 01:08:47,150 INFO conf.Configuration: resource-types.xml not found
2025-09-29 01:08:47,150 INFO resource.ResourceUtils: Unable to find 'resource-types.xml'.
2025-09-29 01:08:47,237 INFO impl.YarnClientImpl: Submitted application application_1758979233826_0002
2025-09-29 01:08:47,275 INFO mapreduce.Job: The url to track the job: http://192.168.1.4:8088/proxy/ap
plication_1758979233826_0002/
2025-09-29 01:08:47,276 INFO mapreduce.Job: Running job: job_1758979233826_0002
2025-09-29 01:08:54,407 INFO mapreduce.Job: Job job_1758979233826_0002 running in uber mode : false
2025-09-29 01:08:54,408 INFO mapreduce.Job: map 0% reduce 0%
2025-09-29 01:09:03,778 INFO mapreduce.Job: map 100% reduce 0%
2025-09-29 01:09:10,957 INFO mapreduce.Job: map 100% reduce 100%
2025-09-29 01:09:11,999 INFO mapreduce.Job: Job job_1758979233826_0002 completed successfully
2025-09-29 01:09:12,166 INFO mapreduce.Job: Counters: 54
  File System Counters
    FILE: Number of bytes read=74
    FILE: Number of bytes written=547391
    FILE: Number of read operations=0
    FILE: Number of large read operations=0
    FILE: Number of write operations=0
    HDFS: Number of bytes read=152
    HDFS: Number of bytes written=44
    HDFS: Number of read operations=8
    HDFS: Number of large read operations=0
    HDFS: Number of write operations=2
    HDFS: Number of bytes read erasure-coded=0
  Job Counters
    Launched map tasks=1
    Launched reduce tasks=1
    Data-local map tasks=1
    Total time spent by all maps in occupied slots (ms)=7781
    Total time spent by all reduces in occupied slots (ms)=4526
    Total time spent by all map tasks (ms)=7781
    Total time spent by all reduce tasks (ms)=4526
    Total vcore-milliseconds taken by all map tasks=7781
    Total vcore-milliseconds taken by all reduce tasks=4526
    Total megabyte-milliseconds taken by all map tasks=7967744
    Total megabyte-milliseconds taken by all reduce tasks=4634624
  Map-Reduce Framework
    Map input records=3
    Map output records=6
    Map output bytes=56
```

Рисунок 35 — Вывод подсчета слов

Действительно, в файле `people.txt` всего 6 слов. В этом нам помогает убедиться Рисунок 36.

A terminal window with a black background and green text. The prompt is [student@192 Data]\$ and the command is cat people.txt. The output shows three lines: Michael, 29, Andy, 30, and Justin, 19. The prompt is then shown again with a cursor.

```
[student@192 Data]$ cat people.txt
Michael, 29
Andy, 30
Justin, 19
[student@192 Data]$
```

Рисунок 36 — Содержимое файла `people.txt`

Функция подсчета слов может быть полезна в ситуациях, например, исследования частоты встречаемости каких-либо слов, выявления популярных тем или анализа частоты запросов в системах.

Мониторинг YARN

1. Запустите два задания MapReduce параллельно.
2. Перейдите в веб-интерфейс YARN и проанализируйте:
 - а. сколько ресурсов выделено каждому заданию,
 - б. какой статус у приложений,
 - в. какие контейнеры создавались.
3. Сделайте вывод: что произойдет, если ресурсов будет недостаточно?

Запустим все тот же word count для двух текстовых файлов одновременно и перейдем в веб-интерфейс (Рисунок 37).

The screenshot shows the Hadoop cluster management interface. The top navigation bar includes links for Namenode Web UI, YARN Web UI, NiFi, and Hue. The main content area displays the Hadoop logo and a sidebar with navigation options like Cluster, About, Nodes, Node Labels, Applications, and Scheduler. The main panel shows Cluster Metrics, Cluster Nodes Metrics, and Scheduler Metrics. A table lists the application metrics, showing 4 Apps Submitted, 0 Apps Pending, 0 Apps Running, 4 Apps Completed, and 0 Containers. Below this, a table lists the application metrics, showing 1 Active Node and 0 Decommissioning Nodes. The Scheduler Metrics section shows the Capacity Scheduler and Scheduling Resource Type. A table lists the application metrics, showing 20 entries. The table has columns for ID, User, Name, Application Type, Application Tags, Queue, Application Priority, and Start Time. The table shows 4 entries, all with status FINISHED.

ID	User	Name	Application Type	Application Tags	Queue	Application Priority	Start Time
application_1758979233826_0004	student	word count	MAPREDUCE		default	0	Mon Sep 01:29:10 +0900 20
application_1758979233826_0003	student	word count	MAPREDUCE		default	0	Mon Sep 01:26:30 +0900 20
application_1758979233826_0002	student	word count	MAPREDUCE		default	0	Mon Sep 01:08:47 +0900 20
application_1758979233826_0001	student	word count	MAPREDUCE		default	0	Sun Sep 22:07:41 +0900 20

Рисунок 37 — Просмотр запущенных процессов

У обоих процессов статус FINISHED.

Ресурсы:

Задание 0003:

- **Memory:** 56779 MB-seconds
- **VCores:** 30 vcore-seconds

Задание 0004:

- **Memory:** 56996 MB-seconds
- **VCores:** 30 vcore-seconds

В каждом процессе было создано по одному контейнеру.

Если бы ресурсов было недостаточно, тогда бы увеличилось время ожидания выполнения процессов, могли бы случиться ошибки или убитые задания.

Исследование репликации (бонусные 2 балла)

1. Измените коэффициент репликации файла `alice_in_wonderland.txt` с 1 на 2.
2. Проверьте через веб-интерфейс HDFS, как изменилась информация о блоках.
3. Объясните, зачем используется репликация в распределённых системах.

Сперва узнаем, какой текущий коэффициент репликации у файла (он будет 1). Затем изменим его на 2. Снова проверим коэффициент (Рисунок 38).

```
[student@192 ~]$ hdfs dfs -ls /user/student/MRtest/alice_in_wonderland.txt
-rw-r--r-- 1 student student 170549 2025-09-27 06:01 /user/student/MRtest/alice_in_wonderland.txt
[student@192 ~]$ hdfs dfs -setrep 2 /user/student/MRtest/alice_in_wonderland.txt
Replication 2 set: /user/student/MRtest/alice_in_wonderland.txt
[student@192 ~]$ hdfs dfs -ls /user/student/MRtest/alice_in_wonderland.txt
-rw-r--r-- 2 student student 170549 2025-09-27 06:01 /user/student/MRtest/alice_in_wonderland.txt
[student@192 ~]$
```

Рисунок 38 — Изменение коэффициента репликации

Просмотрим изменения в браузере (Рисунок 39).




Рисунок 39 — Просмотр изменений в браузере

Репликация в распределённых системах используется для обеспечения отказоустойчивости и повышения доступности данных. Когда данные хранятся в нескольких копиях на разных узлах кластера, система продолжает

функционировать даже при выходе из строя отдельных компонентов. Это обеспечивает непрерывность работы и защиту от потери информации, что особенно критично в производственных средах, где простои недопустимы.

Еще одна важная причина — улучшение производительности и балансировка нагрузки. Наличие нескольких копий данных позволяет распределять запросы на чтение между разными узлами, что снижает нагрузку на каждый отдельный сервер и ускоряет обработку запросов. Клиенты могут получать данные с ближайшей или наименее загруженной реплики, что особенно важно в географически распределенных системах, где задержки сети играют существенную роль.

Репликация также обеспечивает масштабируемость системы, позволяя эффективно обслуживать растущее количество клиентов без деградации производительности. При увеличении нагрузки система может просто добавлять новые реплики для распределения запросов. Кроме того, репликация упрощает восстановление после сбоев — при повреждении или потере данных на одном узле, информация может быть автоматически восстановлена из сохранившихся копий на других узлах без вмешательства администратора и простоев системы.