

Защита практической работы №1

Подготовил студент группы ИНБО-20-23, Школьный Илья Владимирович



СОДЕРЖАНИЕ

- Работа с массивами, статистика и обработка данных
- Работа с таблицами в Pandas
- Визуализация многомерных и категориальных данных
- Скользящее окно на одномерных данных




Задание 1. Работа с массивами, статистика и обработка данных

1. Генерация данных

- сгенерируйте numpy-массив размером 100 с равномерным распределением от -100 до 50 (`numpy.random.uniform`);
- сгенерируйте массив из 100 случайных значений по нормальному распределению со средним 10 и $\sigma = 5$ (`numpy.random.normal`);
- сгенерируйте массив из 100 значений, распределённых по экспоненциальному закону с параметром $\lambda = 0.5$ (`numpy.random.exponential`).
- постройте гистограммы всех трёх массивов на одном графике (используйте `matplotlib` или `seaborn`), нормируйте плотность (`density=True`). Подпишите графики: укажите параметры, сравните формы распределений. Где «тяжёлый хвост»? Где симметрия?









Задание 1. Работа с массивами, статистика и обработка данных

2. Алгебра, фильтрация и статистика

- реализуйте нормализацию z-score вручную, без использования `scikit-learn` и `stats.zscore`;
- реализуйте проверку на выбросы, например, выбросами будут считаться элементы с $|z| > 2.5$;
- постройте гистограмму нормализованных значений и выделите выбросы другим цветом;
- отфильтруйте все элементы, находящиеся в пределах $\pm 1\sigma$, затем — в пределах $\pm 1,5\sigma$. Сравните количество таких элементов;
- вычислите вручную ковариацию, дисперсию и корреляцию Пирсона между двумя массивами;
- вычислите ковариацию, дисперсию и корреляцию Пирсона между двумя массивами с использованием NumPy (`numpy.cov`, `numpy.var`, `numpy.corrcoef`).





The amount of elements in a range of diff sigmas:

Uniform:

Within the limits of 1: 54

Within the limits of 1.5: 91

Normal:

Within the limits of 1: 67

Within the limits of 1.5: 86

Exponential:

Within the limits of 1: 69

Within the limits of 1.5: 93

Manual calculation (uniform and normal spreads):

Variance of a uniform spread: 1991.24887

Variance of a normal spread: 20.83600

Covariation: -30.51743

Pearson Correlation: -0.14982

Calculation using NumPy:

NumPy Variance of a uniform spread: 1991.24887

NumPy Variance of a normal spread: 20.83600

NumPy Covariation: -30.51743

NumPy Pearson Correlation: -0.14982

Results comparison:

Variance uniform: True

Variance normal: True

Covariation: True

Pearson Correlation: True

Outliers analysis:

Uniform: 0, 0.00%

Normal: 2, 2.00%

Exponential: 3, 3.00%





Задание 1. Работа с массивами, статистика и обработка данных

3. Срезы и условия

- выделите из равномерного массива все подпоследовательности длиной 3, в которых сумма > 30 : через цикл `for` и с помощью NumPy. Сравните производительность двух подходов;
- реализуйте вручную алгоритм вычисления экспоненциального сглаживания (ЕМА) с фактором затухания 0.2 для массива с нормальным распределением;
- реализуйте алгоритм вычисления экспоненциального сглаживания (ЕМА) с фактором затухания 0.2 через библиотеку Pandas;
- визуализируйте полученные ЕМА и сравните результаты.







Задание 1. Работа с массивами, статистика и обработка данных

4. Индексация и маски

- преобразуйте массив в матрицу 10×10 (reshape);
- установите в NaN (np.nan) те элементы, которые являются локальными минимумами по строкам.



Задание 2. Работа с таблицами в Pandas

1. Создание DataFrame. Сгенерируйте таблицу на 500 строк с полями:

- `user_id` (уникальные ID); `age` (от 18 до 65);
- `income` (зависит от возраста: например, `income = age * random.normal(1.5, 0.2)`);
- `subscription_date` (случайные даты за последние 2 года);
- `region` (случайно: «Север», «Юг», «Центр», «Восток», «Запад»);
- `is_active` (булевый флаг активности пользователя).
- Код программы генерации таблицы изображен в Листинге 8.



	user_id	age	income	subscription_date	region	is_active
0	1	47	65.75	2024-10-23	Восток	False
1	2	23	37.49	2024-07-17	Центр	True
2	3	64	90.87	2024-01-04	Центр	False
3	4	51	105.07	2025-06-15	Центр	False
4	5	23	33.34	2024-09-16	Центр	False
...	...	...	...	...	...	...
495	496	40	52.89	2025-04-28	Восток	True
496	497	25	37.63	2025-04-09	Юг	False
497	498	27	36.86	2024-11-19	Запад	False
498	499	49	66.41	2024-10-03	Центр	False
499	500	22	36.31	2024-11-15	Юг	False

500 rows × 6 columns



Задание 2. Работа с таблицами в Pandas

2. Работа с признаками

- вычислите `experience_months` — количество месяцев с момента подписки;
- создайте категориальный признак “`income_group`” по квантилям дохода;
- постройте новую метрику — $\text{loyalty_score} = \text{income} / (1 + \text{experience_months})$.



Задание 2. Работа с таблицами в Pandas

3. Фильтрация и агрегации

- найдите средний доход активных пользователей по регионам;
- постройте сводную таблицу: средний `loyalty_score` по регионам и группам дохода;
- найдите 5% пользователей с наибольшим `loyalty_score`



Задание 2. Работа с таблицами в Pandas

4. Обработка пропусков и ошибок

- случайно удалите 5% значений из `income`, замените их средним значением по региону;



Задание 2. Работа с таблицами в Pandas

5. Контроль значений

- реализуйте функцию контроля значений: выбрасывайте строки, где `income` или `age` стали некорректными (например, отрицательными).



Задание 3. Визуализация многомерных и категориальных данных

1. Обзор данных

- ознакомьтесь с описанием признаков;
- проверьте данные на наличие дубликатов и пропусков, устраните их при наличии;
- преобразуйте признаки cut, color, clarity в упорядоченные категории согласно логике качества (например, Fair < Good < Very Good < Premium < Ideal).




Задание 3. Визуализация многомерных и категориальных данных

2. Визуализация одномерных распределений

- постройте гистограмму распределения переменной price с логарифмическим масштабом;
- постройте boxplot для распределения price в зависимости от cut;
- постройте violinplot для price в зависимости от clarity и проанализируйте, где наблюдаются выбросы.





Задание 3. Визуализация многомерных и категориальных данных


3. Анализ многомерных зависимостей

- постройте тепловую карту корреляции между числовыми признаками;
- постройте pairplot для признаков carat, price, depth, закодировав cut как цвет (hue);
- проанализируйте, какая комбинация признаков наиболее визуально предсказывает цену (price).



Тепловая карта корреляции числовых признаков алмазов






Задание 3. Визуализация многомерных и категориальных данных


4. Визуализация категориальных признаков

- постройте сводную таблицу, показывающую среднюю цену в зависимости от cut и color;
- На ее основе постройте тепловую карту и ответьте на следующие вопросы: Какой цвет и огранка в среднем наиболее дорогие? Есть ли закономерности? Если да, то какие?





Задание 4. Скользящее окно на одномерных данных



СПАСИБО ЗА ВНИМАНИЕ!

